

Домашнее задание №1

1. Цель работы
2. Шаг 1. Уточняющие вопросы к заказчику
3. Шаг 2. Выбор модели контракта и обоснование
4. Шаг 3. Реестр рисков
5. Шаг 4. Дорожная карта (Roadmap) и критерии готовности (DoD)

Разработка стратегии, оценка рисков и дорожной карты AI-проекта

Цель:

Разработать стратегию внедрения AI-решения с выбором контрактной модели, оценкой рисков и дорожной картой для согласования с заказчиком.

Шаг 1. Уточняющие вопросы к заказчику

Вопрос 1. Данные о поведении пользователей

Вопрос: «В каком формате и с какой частотой доступны сырые логи поведения (клики, скроллы, время на странице)? Есть ли возможность выгрузки из GA в DWH или логи пишутся локально? Есть ли утвержденная схема событий (event schema) или методология: какие действия пользователя (клик, добавление в избранное, просмотр более 30 сек) считаются сигналом интереса для модели?»

Почему это важно:

- Без сырых логов невозможно обучить персонализированную модель (GA даёт агрегированные данные)
- Если логи отсутствуют, потребуется 2–4 недели на настройку сбора, что сдвигает срок PoC
- Риск: «Мусор на входе = мусор на выходе» → модель не покажет качество, проект закроют

Вопрос 2. Интеграция офлайн-данных

Вопрос: «Как мы связываем пользователя между сайтом и офлайн-магазином (по номеру телефона, карте лояльности, email)? Как часто покупки из 1С должны исключаться из рекомендаций – допустима ли

задержка 15–30 минут или нужно real-time (менее 1 минуты)? Есть ли API для единой интеграции?»

Почему это важно:

- Требование «омниканальности» бессмысленно без синхронизации офлайн-покупок
- Битрикс + 1С — сложная интеграция; без четкого контракта данных возрастает риск рассинхрона
- Риск: клиент видит рекомендацию уже купленного товара → падение доверия к системе

Вопрос 3. Latency и генерация текста

Вопрос: «Требование менее 200ms относится только к выбору товаров или включает также генерацию текстового описания LLM? Допустимо ли асинхронно подгружать сгенерированный текст или использовать кэширование шаблонов?»

Почему это важно:

- Генерация текста на LLM обычно занимает 500–2000ms. Если это входит в лимит 200ms — технически невыполнимо без компромиссов
- Ответ определит архитектуру: синхронный RAG-пайплайн или асинхронная очередь + кэш
- Риск: нарушение SLA → падение конверсии, конфликт с СТО

Вопрос 4. Метрика успеха и атрибуция

Вопрос: «Каков текущий средний чек (AOV) и конверсия блока рекомендаций (укажите, как именно измеряется: клик / добавление в корзину / покупка)? Какую методику атрибуции вы готовы утвердить, чтобы мы могли доказать, что рост AOV на 10% – это результат именно AI? Готовы ли вы выделить holdout-группу (например, 5% пользователей, которые продолжают видеть старые rule-based рекомендации) на время A/B-теста (минимум 2-3 недели)?»

Почему это важно:

- Без базовых метрик невозможно измерить эффект от внедрения
- Без методики атрибуции (A/B-тест, holdout-группа) заказчик может не признать результат
- Риск: «Мы не видим роста» → проект закрывают, несмотря на технический успех

Вопрос 5. Границы безопасности и персональных данных

Вопрос: «Какие именно поля считаются персональными данными (ФИО, телефон, email, cookie_id)? Допускается ли передача обезличенных данных в облачные API (например, для эмбедингов), или

требуется строгий on-prem контур для всех этапов?»

Почему это важно:

- Определяет выбор стека: публичные API (дешево, быстро) vs self-hosted LLM (дорого, сложно)
- Влияет на бюджет: on-prem требует GPU-кластера и MLOps-команды
- Риск: утечка ПДн → штрафы по 152-ФЗ, репутационный ущерб, остановка проекта

Вопрос 6. Бюджет эксплуатации (OpEx)

Вопрос: «Какой месячный бюджет (OpEx) вы готовы выделить на эксплуатацию системы после запуска? Сюда входят: облачные GPU / API-токены, хранение векторной БД, мониторинг, логирование, возможные дообучения модели. Например, до 200 тыс. руб. в месяц или 500 тыс.?»

Почему это важно:

- Архитектурный выбор: от этой цифры напрямую зависит, сможем ли мы использовать LLM для генерации описаний (дорого: \$0.01–0.05/запрос) или ограничимся шаблонами
- Расчёт TCO: $TCO = CapEx + (OpEx \times 36m)$. Без оценки ежемесячных расходов мы не можем предложить реалистичную дорожную карту
- Защита бюджета: если не зафиксировать OpEx-лимит на этапе пресейла, после запуска возникнет конфликт с CFO
- Связь с рисками: риск «рост стоимости инференса» имеет высокий Exposure. Зная лимит, мы можем заранее заложить оптимизации

Вопрос 7. Инфраструктура развертывания

Вопрос: «Какова целевая инфраструктура для Production-окружения: предпочитаете ли вы managed Kubernetes в облаке, готовы ли рассматривать serverless-архитектуру для отдельных компонентов, или есть требование к полностью on-prem развертыванию?»

Почему это важно:

- Определяет выбор стека: Helm-чарты vs Docker Compose vs Serverless Framework
- Влияет на бюджет: managed K8s ≈ \$100–300/мес; on-prem — CapEx на железо + команда поддержки
- Определяет MLOps-пайплайн: CI/CD для K8s vs деплой в Functions
- Риск: если клиент хочет «как у всех в облаке», но по 152-ФЗ данные не могут покидать контур — требуется гибридная архитектура

Вопрос 8. Золотой датасет

Вопрос: «Есть ли у вас эталонный набор данных (Golden Dataset) из 100–500 пар "пользователь / сессия → товар, который реально купили"? Если нет – кто и в какие сроки готов его разметить?»

Почему это важно:

- Без этого мы не сможем объективно измерить качество модели до A/B-теста
- Заказчик сможет бесконечно говорить «мне не нравится», даже если код работает
- Влияет на контракт: без золотого датасета Fixed Price на MVP невозможен

Шаг 2. Выбор модели контракта и обоснование

Общая стратегия: Поэтапное контрактование

В AI-проектах с высокой неопределенностью единый Fixed Price на весь цикл ведет к кассовым разрывам или провалу по качеству. Мы применяем модель, где контракт адаптируется под уровень неопределенности: от разведки данных до масштабирования с управляемым OpEx.

Фаза 0. Data Discovery (2–3 недели)

Модель контракта: Fixed Price (малый бюджет, жесткий скоуп)

Аргументы для CEO:

«Мы не начинаем бурение, не проводя геологоразведку. За фиксированную сумму вы получаете отчет по качеству данных, утвержденный Golden Dataset (100–500 эталонных пар) и точный прогноз TCO. Это защита от инвестиций в проект, где данные изначально непригодны для ML. Без Discovery оценка PoC будет гаданием, а с ним — математикой.»

Аргументы для СТО:

«Аудит проводится в изоляции, без вмешательства в ядро Bitrix и 1С. Мы формализуем контракт данных (API schema, event schema, частоту синхронизации), согласуем границы ПДн (152-ФЗ) и выбираем контур (cloud/on-prem) до написания кода. Результат — готовый blueprint интеграции, который исключит рефакторинг монолита на старте.»

Фаза 1. PoC (Proof of Concept) (1.5–2 месяца)

Модель контракта: Capped T&M (Time & Materials с потолком бюджета)

Аргументы для CEO:

«Максимальная неопределенность еще не снята, поэтому мы делим риск пополам. Вы платите за фактические часы работы экспертов, но бюджет жестко ограничен. Если гипотеза не подтвердится на контрольной точке, мы останавливаемся, экономя до 70% бюджета. Вы покупаете не "магию", а ответ на вопрос: "Решаемо ли это технически и экономически?"»

Аргументы для СТО:

«PoC строится в песочнице. Мы проверяем критические технические гипотезы: укладываемся ли в latency менее 200ms при GenAI, дает ли пайплайн Faithfulness более 0.8 на Golden Dataset, выдерживает ли нагрузку прототип. Скорость валидации важнее качества кода на этом этапе. Мы фиксируем остаточные риски и точный план MVP.»

Фаза 2. MVP (Minimum Viable Product) (2–3 месяца)

Модель контракта: Поэтапный Fixed Price (спринты 2–4 недели)

Аргументы для CEO:

«Неопределенность сужена: данные готовы, стек выбран, пайплайн работает. Теперь мы переходим на короткие фиксированные итерации. Каждый спринт привязан к измеримой бизнес-метрике (CTR, конверсия в корзину). Бюджет предсказуем. Любая новая функция оформляется через Change Request с явным пересчетом TCO — никакого скрытого раздувания бюджета.»

Аргументы для СТО:

«MVP разворачивается как отдельный микросервис с четкими API-контрактами. Мы внедряем базовый MLOps, логирование и мониторинг. Технический долг (осознанный на PoC) ведется в бэклоге и погашается по плану. Интеграция с Bitrix идет через неблокирующие вызовы, гарантируя zero-downtime. Критерии приемки теперь объективны: метрики Golden Dataset + A/B-тест на 5% трафика.»

Фаза 3. Production (3–6 месяцев + поддержка)

Модель контракта: T&M + SLA (с жестким OpEx-лимитом и FinOps)

Аргументы для CEO:

«Система переходит из статуса R&D в стратегический актив. Мы переходим на модель поддержки с гарантированным SLA. $TCO = CapEx + (OpEx \times 36m)$. Месячный бюджет на инференс, векторную БД и ретрейны зафиксирован заранее. Внедренные механизмы FinOps держат стоимость запроса в рамках утвержденного лимита. Вы платите за стабильный рост AOV, а не за непредсказуемые счета за токены.»

Аргументы для СТО:

«Фокус на отказоустойчивости и автоматизации. Развернут полноценный CI/CD, автоматический retrain

при data drift, мониторинг latency p95 и ошибок. Безопасность (152-ФЗ) встроена в архитектуру: PII маскируется на входе, данные не покидают контур. Система соответствует SLA 99.9%. Команда интегратора передает знания и документацию вашей команде поддержки.»

Итоговая матрица этапов и контрактов

Этап	Уровень неопределенности	Модель контракта	Ключевой вопрос этапа
Discovery	Максимальный	Fixed Price	Пригодны ли данные и понятна ли интеграция?
PoC	Высокий	Capped T&M	Решаемо ли это технически в заданных NFR?
MVP	Средний	Позэтапный Fixed Price	Готовы ли пользователи и растет ли бизнес-метрика?
Production	Низкий	T&M + SLA (OpEx Cap)	Стабильно, масштабируемо и экономично ли это?

Шаг 3. Реестр рисков

Таблица рисков

ID	Категория	Описание риска	Вероятность (1-5)	Влияние (1-5)	Risk Score	Стратегия
R01	Data Risks	Отсутствие сырых логов поведения делает невозможным обучение персонализированной модели. Риск срыва PoC	4	5	20 (Critical)	Mitigate + Transfer
R02	Model Risks	LLM генерирует ложные причины рекомендаций (галлюцинации). Риск	3	4	12 (High)	Mitigate

ID	Категория	Описание риска	Вероятность (1-5)	Влияние (1-5)	Risk Score	Стратегия
		репутационного ущерба				
R03	Infrastructure Risks	Генерация LLM занимает 1-2 сек, а требование бизнеса менее 200ms. Риск нарушения SLA	4	4	16 (Critical)	Mitigate + Avoid
R04	Security & Legal Risks	Передача ПДн в публичные LLM API. Риск штрафов 152-ФЗ	2	5	10 (High)	Avoid
R05	Infrastructure Risks	Непредсказуемый рост расходов на токены/GPU при масштабировании. Риск кассового разрыва	4	5	20 (Critical)	Mitigate + Transfer
R06	Model Risks	Изменение ассортимента или сезонности приводит к неактуальным рекомендациям (Model Drift)	3	3	9 (Medium)	Mitigate

Детальный обзор рисков

R-01 — Data Risks (Quality/Scarcity)

Описание:

В кейсе указано: «сырых логов на своих серверах почти нет», данные о кликах — только в Google Analytics (агрегированные). Без событийной модели и raw-логов невозможно обучить персонализированную рекомендательную модель. Это фундаментальный риск: если данных нет, то и модели нет.

План митигации:

- 1. На этапе Data Discovery (2-3 недели) провести аудит данных и зафиксировать пробелы в отчете

2. Для PoC использовать stub API + синтетические данные, но с явным указанием ограничения в отчёте
3. В контракт включить пункт: «Заказчик обеспечивает доступ к event-логам в течение 5 рабочих дней после старта PoC»
4. Заложить в смету MVP 2 спринта на настройку ETL-пайплайна для сбора поведенческих данных
5. Триггер эскалации: если после 2 недель Discovery нет утверждённой event schema — активировать резервный план (упрощённая модель на основе каталога + 1С)

R-02 — Model Risks (Hallucinations)

Описание:

GenAI-модель может генерировать убедительные, но фактически неверные обоснования рекомендаций. Это подрывает доверие пользователей и создаёт репутационные риски. В отличие от классического ML, здесь ошибка не просто «неверная метка», а «правдоподобная ложь».

План митигации:

1. Внедрить RAG-пайплайн с проверкой контекста: ответы генерируются только на основе верифицированных данных каталога
2. Использовать Golden Dataset (100–500 пар «сессия → купленный товар») и метрики Ragas (Faithfulness более 0.8) как критерий приемки PoC
3. Добавить human-in-the-loop валидацию на MVP: выборка 5–10% рекомендаций проходит проверку экспертом клиента
4. Триггер эскалации: если на тестовом прогоне (50 запросов) Faithfulness менее 0.7 — остановить генерацию описаний и переключиться на шаблонные тексты

R-03 — Infrastructure Risks (Latency)

Описание:

Требование заказчика: рекомендации должны грузиться менее 200ms. Однако генерация текста на LLM обычно занимает 500–2000ms. Если это входит в лимит — технически невыполнимо без компромиссов, что ведёт к нарушению SLA и падению конверсии.

План митигации:

1. Архитектура: Semantic Caching (Redis/Qdrant) + асинхронная подгрузка генеративного текста (сначала товары, потом описание)
2. Model Routing: простые запросы → дешёвая/быстрая модель, сложные → SOTA модели
3. DoD PoC: p95 latency менее 200ms на Golden Dataset при нагрузке 50 RPS
4. Триггер эскалации: если p95 latency на нагрузочном тесте превышает 300ms — активировать fallback на шаблонные описания

R-04 — Security & Legal Risks (Compliance / Data Leakage)

Описание:

Кейс содержит данные из 1С (чеки, ФИО, телефоны). Отправлять это в OpenAI/Cloud без обработки — нарушение 152-ФЗ. Риск штрафов, репутационного ущерба и полной остановки проекта.

План митигации:

1. Архитектурный паттерн «Masking Gateway»: данные обезличиваются до выхода из контура TechnoMart
2. Использование On-prem моделей для контура с ПДн
3. Юридический аудит на этапе Discovery: классификация полей (что именно считается ПДн)
4. Триггер эскалации: если в логах LLM API обнаруживается незамазанный номер телефона — немедленная остановка пайплайна

R-05 — Infrastructure Risks (Cost Surge)

Описание:

В кейсе бюджет на разработку есть, но «дорогое железо требует согласования». Значит, есть риск, что OpEx (токены/GPU) съест бюджет поддержки. При масштабировании на 100% трафика стоимость инференса может вырасти непропорционально.

План митигации:

1. Фиксация OpEx Cap в контракте Production
2. Внедрение FinOps-мониторинга (cost per request, cost per 1k tokens)
3. Архитектурные оптимизации: 4-bit quantization, semantic caching, model distillation
4. Триггер эскалации: если стоимость 1000 запросов превышает плановую на 20% — автоматический fallback на более дешёвую модель

R-06 — Model Risks (Drift)

Описание:

Изменение ассортимента, сезонности или поведения пользователей приводит к тому, что модель, обученная на исторических данных, выдаёт неактуальные рекомендации.

План митигации:

1. Настройка автоматического ретрейна/обновления индекса (Data Freshness менее 15 минут согласно NFR)

2. Мониторинг метрик качества в Production
3. Триггер эскалации: если конверсия блока рекомендаций падает ниже baseline на 10% в течение недели — запуск переобучения модели

Шаг 4. Дорожная карта (Roadmap) и критерии готовности (DoD)

Сводная дорожная карта

Этап	Срок	Что делаем	Ключевые активности
Discovery (Подготовка)	2-3 нед	Разбираемся в данных и требованиях	• Аудит: какие данные есть и какого они качества • Создаем эталонный набор примеров (Golden Dataset) • Уточняем технические требования (NFR) • Выбираем технологии
PoC (Проверка гипотезы)	1.5-2 мес	Доказываем, что технология работает	• Создаем прототип модели рекомендаций • Тестируем генерацию описаний через ИИ (GenAI) • Проверяем скорость работы
MVP (Первый релиз)	2-3 мес	Запускаем для реальных пользователей	• Интегрируем с сайтом (Битрикс) • Запускаем на 5% посетителей (A/B-тест) • Сравниваем со старой системой
Production (Полноценный запуск)	3-6 мес+	Масштабируем на всех пользователей	• Запускаем на 100% трафика (2 млн MAU) • Настраиваем автоматическое обновление модели (retrain) • Контролируем расходы (FinOps)

Критерии приемки (DoD) по этапам — подробно

Discovery (Подготовка)

- **Event schema утверждена** — договорились, какие действия пользователя отслеживаем (клик, добавление в корзину, просмотр >30 сек)
- **Golden Dataset подписан** — 100-500 примеров «сессия пользователя → товар, который купили», утверждено заказчиком
- **Реестр рисков обновлен** — согласовали план действий по основным рискам
- **Выбран контур** — cloud / on-prem / hybrid (где будут работать модели)

PoC (Proof of Concept)

- **Модель лучше правил** — точность рекомендаций на 15% выше текущей rule-based системы
- **Качество описаний** — Faithfulness >0.8 (описания соответствуют товарам, нет «выдумок», метрика оценивает соответствие ответа контексту)
- **Скорость** — 95% запросов обрабатываются быстрее 200 мс при нагрузке 50 запросов/сек
- **Отчет с рисками** — задокументировали остаточные технические риски и план MVP

MVP (Minimum Viable Product)

- **Запуск на 5% трафика** — реальная нагрузка, holdout-группа 5% видит старые рекомендации
- **Статистическая значимость** — p-value <0.05 (результат не случайный, тест 2-3 недели)
- **Базовый мониторинг** — логи, метрики, уведомления о проблемах
- **Документация** — API, инструкции, план масштабирования

Production

- **SLA 99.9%** — система доступна почти всегда, 99% запросов <300 мс
- **Автоматическое обновление** — переобучение модели при изменении данных (data drift — когда распределение входных данных меняется со временем)
- **Контроль расходов** — стоимость одного запроса ≤плановой
- **Безопасность** — 0 утечек персональных данных, все данные маскируются